

組合せ最適化特論

第10回 (劣モジュラ最大化)

担当: 相馬 輔

2026/7/16

目次

1. 劣モジュラ最大化

- 定式化
- モデリング例

2. 貪欲法

- 古典貪欲法
- 連続貪欲法

目次

1. 劣モジュラ最大化

- 定式化
- モデリング例

2. 貪欲法

- 古典貪欲法
- 連続貪欲法

単調劣モジュラ関数最大化 [Nemhauser, Wolsey, and Fisher 1978]

$f : 2^V \rightarrow \mathbb{R}_+ \dots$ 非負**単調**劣モジュラ, $f(\emptyset) = 0$
[単調 $\stackrel{\text{def}}{\iff} f(X) \leq f(Y) \quad (X \subseteq Y)$]

$$\max \quad f(X) \quad \text{s.t.} \quad X \in \mathcal{C}$$

単調劣モジュラ関数最大化 [Nemhauser, Wolsey, and Fisher 1978]

$f : 2^V \rightarrow \mathbb{R}_+ \dots$ 非負**単調**劣モジュラ, $f(\emptyset) = 0$

[単調 $\stackrel{\text{def}}{\iff} f(X) \leq f(Y) \quad (X \subseteq Y)$]

$$\max \quad f(X) \quad \text{s.t.} \quad X \in \mathcal{C}$$

$|X| \leq k, \sum_{i \in X} w(i) \leq 1$ など

単調劣モジュラ関数最大化 [Nemhauser, Wolsey, and Fisher 1978]

$f : 2^V \rightarrow \mathbb{R}_+ \dots$ 非負**単調**劣モジュラ, $f(\emptyset) = 0$

[単調 $\stackrel{\text{def}}{\iff} f(X) \leq f(Y) \quad (X \subseteq Y)$]

$$\max \quad f(X) \quad \text{s.t.} \quad X \in \mathcal{C}$$

$|X| \leq k, \sum_{i \in X} w(i) \leq 1$ など

応用:

- 文書要約 [Lin and Bilmes 2011]
- モデル解釈 [Ribeiro, Singh, and Guestrin 2016]
- 変数選択 [Das and Kempe 2011; Elenberg et al. 2018]

単調劣モジュラ最大化

名前	制約	近似比
サイズ制約	$ X \leq k$	$1 - 1/e$ [NWF '78]
ナップサック制約	$\sum_{i \in X} w_i \leq 1$	$1 - 1/e$ [Sviridenko 2004]
マトロイド制約	$X \in \mathcal{I}$	$1 - 1/e$ [Calinescu et al. 2011]


- $(1 - 1/e)$ 近似 $\iff f(X) \geq (1 - 1/e) \max_{X^* \in \mathcal{C}} f(X^*)$ となる X を出力
- 近似比 $1 - 1/e$ はオラクルモデルの多項式時間アルゴリズムの中で最良 [Nemhauser and Wolsey 1978]

例: 最大被覆問題

最大被覆問題

入力 V : 基地局候補地の集合, $k \in \mathbb{Z}_+$


出力 $S \subseteq V$ で $|S| \leq k$ かつ S に設置したときの被覆範囲が最大となるもの



例: 不可分財の分配

$U = \{v_1, \dots, v_n\}$... 財の集合
 f_i ... i さんの効用関数, 単調劣モ
($i = 1, \dots, m$)


社会効用 $\sum_{i=1}^m f_i(X_i)$ が最大の分配
($X_1, \dots, X_m$) を求めたい.



例: 不可分財の分配

- $V := U$ の m 個のコピー
- $f(X) := \sum_{i=1}^m f_i(X \cap U_i)$
- $\mathcal{C}$: V 上の分割マトロイド (各財は1人まで割当可能)

分割マトロイド制約の単調劣モ最大化



例: 文書要約 [Lin and Bilmes 2011]

V : 元文書の文全ての集合, $X \subseteq V \longleftrightarrow$ 要約

$r_1, \dots, r_K$: 参照文

$c_e(X)$ = n-gram e が要約 X に現れる回数

$M_{e,i}$ = n-gram e が参照文 r_i に現れる回数

ROUGE-N

$$f(X) = \sum_{r \in R} \sum_{e: \text{文 } r \text{ に含まれる n-gram}} \min\{c_e(X), M_{e,i}\}$$

(※ 簡単のため正規化定数は省いた)

- ROUGE-N は単調劣モジュラ関数
- サイズ制約 $\longleftrightarrow$ 要約に使える文の数に制約
- ナップサック制約 $\longleftrightarrow$ 要約の文字数に制約

要約文

民間英語試験の延期
を決定した。

参照文 A

英語教育が専門の〇〇
氏は、民間英語試験は
問題が多く、...

例: モデル解釈 (SP-LIME) [Ribeiro, Singh, and Guestrin 2016]

近年の機械学習モデルは複雑で解釈しづらい. → **解釈性**

Local Interpretable Model-agnostic Explanations (LIME)

各訓練データに対して, “特徴量ごとの予測への貢献度” を計算してくれる手法



引用: LIME のチュートリアル

データセット全体での挙動を知りたい場合は？

例: モデル解釈 (SP-LIME) [Ribeiro, Singh, and Guestrin 2016]


V = 訓練データの集合

U = 特徴量の集合

a_{ij} = データ i に対する特徴量 j の LIME スコア

$G = (V, U; E) \dots a_{ij} > 0$ の (i, j) に枝を引いた二部グラフ

$w_j := \sqrt{\sum_{i \in V} a_{ij}}$... 特徴量 j の重み



$$f(X) = \sum_{j \in \Gamma_G(X)} w_j$$

- モデルの全体的挙動を理解する上で多様な訓練データを抽出できる
- サイズ制約 $\longleftrightarrow$ 抽出するデータ数に制約

例: 変数選択

[Das and Kempe 2011; Elenberg et al. 2018]

$$V = \{1, \dots, n\}$$

$\mathbf{x}_i$: 説明変数 ($i = 1, \dots, n$), $\mathbf{y}$: 被説明変数

$$f(X) = \|\mathbf{y}\|_2^2 - \min_{\beta: \text{supp}(\beta) \subseteq X} \left\| \mathbf{y} - \sum_{i=1}^n \beta_i \mathbf{x}_i \right\|_2^2$$

... X に入っている変数だけ使ったときの最良残差

- 抑圧変数がない $\implies f$: 単調劣モジュラ
- $X = [\mathbf{x}_1 \dots \mathbf{x}_n]$ に対する RIP 仮定 $\implies f$: 弱劣モジュラ (近似的に劣モジュラ)

目次

1. 劣モジュラ最大化

- 定式化
- モデリング例

2. 貪欲法

- 古典貪欲法
- 連続貪欲法

最大化アルゴリズム

サイズ制約 $|X| \leq k$ (組合せ的アルゴリズム)

- 古典貪欲法 [Nemhauser, Wolsey, and Fisher 1978]
- 確率的貪欲法 [Mirzasoleiman et al. 2015]

一般の制約 $X \in \mathcal{C}$ (連続最適化的アルゴリズム)

- 連続貪欲法 [Calinescu et al. 2011; Chekuri, Vondrák, and Zenklusen 2010; Chekuri, Vondrák, and Zenklusen 2014]

最大化アルゴリズム

サイズ制約 $|X| \leq k$ (組合せ的アルゴリズム)

- **古典貪欲法** [Nemhauser, Wolsey, and Fisher 1978]
- **確率的貪欲法** [Mirzasoleiman et al. 2015]

一般の制約 $X \in \mathcal{C}$ (連続最適化的アルゴリズム)

- **連続貪欲法** [Calinescu et al. 2011; Chekuri, Vondrák, and Zenklusen 2010; Chekuri, Vondrák, and Zenklusen 2014]

古典貪欲法

[Nemhauser, Wolsey, and Fisher 1978]

- 1: $X_0 \leftarrow \emptyset$
- 2: **for** $i = 1, \dots, k$:
- 3: $a \in V \setminus X_{i-1}$ のうち $f(X_{i-1} \cup a)$ が最大のものを求め, a_i とする.
- 4: $X_i \leftarrow X_{i-1} \cup a_i$
- 5: **return** $X = X_k$

古典貪欲法 [Nemhauser, Wolsey, and Fisher 1978]

```
1:  $X_0 \leftarrow \emptyset$   
2: for  $i = 1, \dots, k$  :  
3:    $a \in V \setminus X_{i-1}$  のうち  $f(X_{i-1} \cup a)$  が最大のものを求め,  $a_i$  とする.  
4:    $X_i \leftarrow X_{i-1} \cup a_i$   
5: return  $X = X_k$ 
```

- 貪欲アルゴリズムの出力を X とすると,

$$f(X) \geq (1 - 1/e) \max_{X^*: |X^*|=k} f(X^*)$$

最適値

古典貪欲法の解析

補題

f : 劣モジュラ

$$f(X \cup Y) \leq f(X) + \sum_{a \in Y \setminus X} [f(X \cup a) - f(X)]$$

古典貪欲法の解析

補題

f : 劣モジュラ

$$f(X \cup Y) \leq f(X) + \sum_{a \in Y \setminus X} [f(X \cup a) - f(X)]$$

補題

各 $i = 1, 2, \dots, k$ に対して

$$f(X_i) - f(X_{i-1}) \geq \frac{1}{k} [f(X^*) - f(X_{i-1})]$$

X^* : 最適解

$$X_0 = \emptyset$$

$$X_i = X_{i-1} \cup a_i$$

$$a_i \in \operatorname{argmax}_{a \in V \setminus X_{i-1}} f(X_{i-1} \cup a)$$

古典貪欲法の解析

補題

f : 劣モジュラ

$$f(X \cup Y) \leq f(X) + \sum_{a \in Y \setminus X} [f(X \cup a) - f(X)]$$

補題

各 $i = 1, 2, \dots, k$ に対して

$$f(X_i) - f(X_{i-1}) \geq \frac{1}{k} [f(X^*) - f(X_{i-1})]$$

X^* : 最適解

補題

各 $i = 0, 1, 2, \dots, k$ に対して

$$f(X^*) - f(X_i) \leq \left(1 - \frac{1}{k}\right)^i f(X^*)$$

古典貪欲法の解析

補題

f : 劣モジュラ

$$f(X \cup Y) \leq f(X) + \sum_{a \in Y \setminus X} [f(X \cup a) - f(X)]$$

補題

各 $i = 1, 2, \dots, k$ に対して

$$f(X_i) - f(X_{i-1}) \geq \frac{1}{k} [f(X^*) - f(X_{i-1})]$$

X^* : 最適解

補題

各 $i = 0, 1, 2, \dots, k$ に対して

$$f(X^*) - f(X_i) \leq \left(1 - \frac{1}{k}\right)^i f(X^*)$$

定理

$$f(X_k) \geq (1 - 1/e) f(X^*)$$

古典貪欲法 [Nemhauser, Wolsey, and Fisher 1978]

```
1:  $X_0 \leftarrow \emptyset$ 
2: for  $i = 1, \dots, k$  :
3:    $a \in V \setminus X_{i-1}$  のうち  $f(X_{i-1} \cup a)$  が最大のものを求め,  $a_i$  とする.
4:    $X_i \leftarrow X_{i-1} \cup a_i$ 
5: return  $X = X_k$ 
```

- 貪欲アルゴリズムの出力を X とすると,

$$f(X) \geq (1 - 1/e) \max_{X^*: |X^*|=k} f(X^*)$$

最適値

- $O(nk)$ 回の f の関数値評価が必要 ($n = |V|$, k : サイズ制約)
→ 応用によっては重すぎる

確率的貪欲法 [Mirzasoleiman et al. 2015]

$\varepsilon > 0$ を固定.

- 1: $X_0 \leftarrow \emptyset$
- 2: **for** $i = 1, \dots, k$:
- 3: $R_i := V \setminus X_{i-1}$ から $\frac{n}{k} \log \frac{1}{\varepsilon}$ 個ランダムサンプル
- 4: $a_i \in \operatorname{argmax}_{a \in R_i} f(X_{i-1} \cup a)$
- 5: $X_i \leftarrow X_{i-1} \cup a_i$
- 6: **return** $X = X_k$

確率的貪欲法 [Mirzasoleiman et al. 2015]

$\varepsilon > 0$ を固定.

```
1:  $X_0 \leftarrow \emptyset$ 
2: for  $i = 1, \dots, k$  :
3:    $R_i := V \setminus X_{i-1}$  から  $\frac{n}{k} \log \frac{1}{\varepsilon}$  個ランダムサンプル
4:    $a_i \in \operatorname{argmax}_{a \in R_i} f(X_{i-1} \cup a)$ 
5:    $X_i \leftarrow X_{i-1} \cup a_i$ 
6: return  $X = X_k$ 
```

- $\mathbb{E}[f(X)] \geq (1 - 1/e - \varepsilon)f(X^*)$
- $O(n \log(1/\varepsilon))$ 回の関数値評価
古典貪欲法の $O(nk)$ に比べて改善！

最大化アルゴリズム

サイズ制約 $|X| \leq k$ (組合せ的アルゴリズム)

- 古典貪欲法 [Nemhauser, Wolsey, and Fisher 1978]
- 確率的貪欲法 [Mirzasoleiman et al. 2015]

一般の制約 $X \in \mathcal{C}$ (連続最適化的アルゴリズム)

- **連続貪欲法** [Calinescu et al. 2011; Chekuri, Vondrák, and Zenklusen 2010; Chekuri, Vondrák, and Zenklusen 2014]

連続貪欲法

[Calinescu et al. 2011]

元問題

$$\max \{f(X) : X \in \mathcal{C}\}$$

連続貪欲法

[Calinescu et al. 2011]

元問題

$$\max \{f(X) : X \in \mathcal{C}\}$$

①連続緩和

緩和問題

$$\max \{F(\boldsymbol{x}) : \boldsymbol{x} \in P\}$$

連続貪欲法

[Calinescu et al. 2011]

元問題

$$\max \{f(X) : X \in \mathcal{C}\}$$

①連続緩和

緩和問題

$$\max \{F(\mathbf{x}) : \mathbf{x} \in P\}$$

②連続貪欲法


$$\mathbf{x} \in P$$

s.t.


$$F(\mathbf{x}) \geq (1 - 1/e)f(X^*)$$

X^* : 最適解

連続貪欲法 [Calinescu et al. 2011]



連続貪欲法 [Calinescu et al. 2011]



多重線形拡張 (multilinear extension)

f の多重線形拡張 $F : [0, 1]^n \rightarrow \mathbb{R}$

$$\begin{aligned} F(\mathbf{x}) &:= \sum_{S \subseteq V} f(S) \prod_{i \in S} x_i \prod_{i \notin S} (1 - x_i) \\ &= \mathbb{E}[f(R(\mathbf{x}))] \end{aligned}$$

$R(\mathbf{x})$: 要素 i を確率 x_i で独立に含むランダム集合

注 $F, \nabla F$ は任意の精度で近似的に求められる (サンプリング).
以下, 簡単のため $F, \nabla F$ を与えるオラクルがあるものとする.


多重線形拡張 (multilinear extension)

性質

- $F(\mathbf{1}_X) = f(X)$
- f : 単調 $\implies \nabla F \geq \mathbf{0}$
- f : 劣モ $\implies \frac{\partial^2 F}{\partial x_i \partial x_j} \leq 0 \ (i \neq j)$

特に F は非負方向に凹,
 $\mathbf{e}_i - \mathbf{e}_j$ 方向に凸

※一般には**凸でも凹でもない**



多重線型拡張の性質

補題

f : 単調 $\implies \nabla F \geq 0$

(証明) $i \in V$ を任意に取る. $\nabla F(\mathbf{x})_i$ を計算してみると

$$\nabla F(\mathbf{x})_i = \sum_{X \subseteq V \setminus i} f(X \cup i) \Pr(X) - \sum_{X \subseteq V \setminus i} f(X) \Pr(X).$$

ここで, $\Pr(X) = \prod_{k \in X} x_k \prod_{k \notin X: k \neq i} (1 - x_k)$ である. f の単調性より $f(X \cup i) - f(X) \geq 0$ なので, $\nabla F(\mathbf{x})_i \geq 0$.



多重線型拡張の性質

補題

f : 劣モ $\implies \frac{\partial^2 F}{\partial x_i \partial x_j} \leq 0$ ($i \neq j$)

特に $\varphi(t) = F(\mathbf{x} + t\mathbf{d})$ ($\mathbf{d} \geq \mathbf{0}$) は凹関数, $\psi(t) = F(\mathbf{x} + t(\mathbf{e}_i - \mathbf{e}_j))$ は凸関数

(証明) $i = j$ の場合は自明に $\frac{\partial^2 F}{\partial x_i \partial x_j} = 0$. $i \neq j$ のとき,

$$\frac{\partial^2 F}{\partial x_i \partial x_j}(\mathbf{x}) = \sum_{X \subseteq V \setminus \{i, j\}} [f(X \cup i \cup j) + f(X) - f(X \cup i) - f(X \cup j)] \Pr(X).$$

ここで, $\Pr(X) = \prod_{k \in X} x_k \prod_{k \notin X: k \neq i, j} (1 - x_k)$ である. 劣モジユラ性より $f(X \cup i \cup j) + f(X) - f(X \cup i) - f(X \cup j) \leq 0$ なので $\frac{\partial^2 F}{\partial x_i \partial x_j}(\mathbf{x}) \leq 0$. □

多重線型拡張の性質

補題

f : 劣モ $\implies \frac{\partial^2 F}{\partial x_i \partial x_j} \leq 0 \ (i \neq j)$

特に $\varphi(t) = F(\mathbf{x} + t\mathbf{v}) \ (\mathbf{v} \geq \mathbf{0})$ は凹関数, $\psi(t) = F(\mathbf{x} + t(\mathbf{e}_i - \mathbf{e}_j))$ は凸関数

(証明) 連鎖律より

$$\varphi''(t) = \sum_{i,j \in V} \frac{\partial^2 F}{\partial x_i \partial x_j}(\mathbf{x} + t\mathbf{v}) v_i v_j$$

であるが, $\frac{\partial^2 F}{\partial x_i \partial x_j}(\mathbf{x} + t\mathbf{v}) \leq 0$ で, 仮定より $v_i, v_j \geq 0$ であるから, $\varphi''(t) \leq 0$. よって φ は凹関数.

多重線型拡張の性質

補題

f : 劣モ $\implies \frac{\partial^2 F}{\partial x_i \partial x_j} \leq 0 \ (i \neq j)$

特に $\varphi(t) = F(\mathbf{x} + t\mathbf{v}) \ (\mathbf{v} \geq \mathbf{0})$ は凹関数, $\psi(t) = F(\mathbf{x} + t(\mathbf{e}_i - \mathbf{e}_j))$ は凸関数

(証明) 連鎖律より


$$\varphi''(t) = \sum_{i,j \in V} \frac{\partial^2 F}{\partial x_i \partial x_j}(\mathbf{x} + t\mathbf{v}) v_i v_j$$

であるが, $\frac{\partial^2 F}{\partial x_i \partial x_j}(\mathbf{x} + t\mathbf{v}) \leq 0$ で, 仮定より $v_i, v_j \geq 0$ であるから, $\varphi''(t) \leq 0$. よって φ は凹関数.

再び連鎖律より

$$\psi''(t) = -2 \frac{\partial^2 F}{\partial x_i \partial x_j}(\mathbf{x} + t(\mathbf{e}_i - \mathbf{e}_j)) \geq 0$$

連続貪欲法 [Calinescu et al. 2011]



連続貪欲法 (連続時間版)

連続緩和問題

$$\max F(\boldsymbol{x}) \quad \text{s.t.} \quad \boldsymbol{x} \in P$$


連続貪欲法 (連続時間版)

連続緩和問題

$$\max F(\boldsymbol{x}) \quad \text{s.t.} \quad \boldsymbol{x} \in P$$

以下の微分方程式に従って $\boldsymbol{x}(t)$ を動かす

$$\begin{aligned} \boldsymbol{x}(0) &= \mathbf{0} \\ \frac{d\boldsymbol{x}(t)}{dt} &= \operatorname{argmax}_{\boldsymbol{v} \in P} \nabla F(\boldsymbol{x}(t))^{\top} \boldsymbol{v} \end{aligned}$$



連続貪欲法 (連続時間版)

連続緩和問題

$$\max F(\mathbf{x}) \quad \text{s.t.} \quad \mathbf{x} \in P$$

以下の微分方程式に従って $\mathbf{x}(t)$ を動かす


$$\begin{aligned} \mathbf{x}(0) &= \mathbf{0} \\ \frac{d\mathbf{x}(t)}{dt} &= \operatorname{argmax}_{\mathbf{v} \in P} \nabla F(\mathbf{x}(t))^{\top} \mathbf{v} \end{aligned}$$

定理 ([Calinescu et al. 2011])

f : 単調劣モ, P : down closed

$\implies \mathbf{x}(1) \in P$ かつ

$$F(\mathbf{x}(1)) \geq (1 - 1/e) \max_{\mathbf{x}^* \in P} F(\mathbf{x}^*)$$



定理の証明


$\Psi(t) := e^{t-1}F(\mathbf{x}(t))$ とする. $\frac{d\Psi}{dt} = e^{t-1}[F(\mathbf{x}(t)) + \nabla F(\mathbf{x}(t))^\top \frac{d\mathbf{x}(t)}{dt}]$.

$\mathbf{x}^* \in P$ を最適解, $\mathbf{x}^* \vee \mathbf{x}(t)$ を $\mathbf{x}^*$ と $\mathbf{x}(t)$ の成分ごとに $\max$ をとったベクトルとする.

$$\begin{aligned} F(\mathbf{x}^*) &\leq F(\mathbf{x}^* \vee \mathbf{x}(t)) \\ &\leq F(\mathbf{x}(t)) + \nabla F(\mathbf{x}(t))^\top (\mathbf{x}^* \vee \mathbf{x}(t) - \mathbf{x}(t)) \\ &\leq F(\mathbf{x}(t)) + \nabla F(\mathbf{x}(t))^\top \mathbf{v}(t) \\ &= F(\mathbf{x}(t)) + \nabla F(\mathbf{x}(t))^\top \frac{d\mathbf{x}(t)}{dt} \end{aligned}$$

$$\therefore \frac{d\Psi}{dt} \geq e^{t-1}F(\mathbf{x}^*).$$

$$[0, 1] \text{ で積分: } \Psi(1) - \Psi(0) = F(\mathbf{x}(1)) \geq (1 - e^{-1})F(\mathbf{x}^*).$$




連続貪欲法 (離散時間版)

実際には微分方程式を厳密に解くことはできないので、時間を離散化して近似する

```
1:  $\mathbf{x}(0) = \mathbf{0}$   
2: for  $t = 0, \delta, 2\delta, \dots, 1 - \delta$  :  
3:    $\mathbf{v}(t) \in \operatorname{argmax}_{\mathbf{v} \in P} \nabla F(\mathbf{x}(t))^{\top} \mathbf{v}$  を求める  
4:    $\mathbf{x}(t + \delta) \leftarrow \mathbf{x}(t) + \delta \mathbf{v}(t)$   
5: return  $\mathbf{x}(1)$ 
```

- Frank-Wolfe 法の亜種
- 精度 $\varepsilon > 0$ に応じて 時間幅 δ を十分小さく取れば、同様の仮定のもと $F(\mathbf{x}) \geq (1 - 1/e - \varepsilon) \max_{\mathbf{x}^* \in P} F(\mathbf{x}^*)$

連続貪欲法 [Calinescu et al. 2011]



丸めアルゴリズム

連続貪欲法で得られる緩和解 x は $\{0, 1\}$ ベクトルとは限らないので、 $\{0, 1\}$ ベクトルに丸める必要がある。

→ **制約ごとに丸めアルゴリズムを設計**

マトロイド制約


- Pipage Rounding [Calinescu et al. 2011]
- Swap Rounding [Chekuri, Vondrák, and Zenklusen 2010]

その他の制約

- Contention Resolution Scheme [Chekuri, Vondrák, and Zenklusen 2014]

Pipage Rounding [Calinescu et al. 2011]

- 1 x_i, x_j が $\{0,1\}$ でない $i, j \in V$ を取る
- 2 $\alpha_+ = \max\{\alpha \geq 0 : \mathbf{x} + \alpha(\mathbf{e}_i - \mathbf{e}_j) \in P\}$
 $\alpha_- = \max\{\alpha \geq 0 : \mathbf{x} - \alpha(\mathbf{e}_i - \mathbf{e}_j) \in P\}$
- 3 $\mathbf{x}_+ = \mathbf{x} + \alpha_+(\mathbf{e}_i - \mathbf{e}_j)$, $\mathbf{x}_- = \mathbf{x} - \alpha_-(\mathbf{e}_i - \mathbf{e}_j)$ のうち F の値が大きいものに $\mathbf{x}$ を更新
- 4 P をぶつかった面に制限して 1 に戻る




定理

P : マトロイド多面体のとき, Pipage Rounding の出力 $\bar{\mathbf{x}}$ は $\{0,1\}$ ベクトルで,
 $F(\bar{\mathbf{x}}) \geq F(\mathbf{x})$ を満たす ($\mathbf{x}$: Pipage Rounding の初期点)

劣モジュラ最大化: 発展的な話題

整数格子点上の劣モジュラ最大化

- 最適予算配分問題
- 最大化アルゴリズム




連続劣モジュラ関数

- 非凸連続最適化 (連続 DR 劣モジュラ関数)

オンライン劣モジュラ最大化

- 近似 no-regret アルゴリズム
- 連続 DR 劣モジュラ関数の CVaR 最大化



参考文献

- Calinescu, G., C. Chekuri, M. Pál, and J. Vondrák (2011). "Maximizing a monotone submodular function subject to a matroid constraint". In: *SIAM Journal on Computing* 40.6, pp. 1740–1766.
- Chekuri, C., J. Vondrák, and R. Zenklusen (2010). "Dependent randomized rounding via exchange properties of combinatorial structures". In: *Proceedings of IEEE 51st Annual Symposium on Foundations of Computer Science (FOCS)*, pp. 575–584.
- (2014). "Submodular function maximization via the multilinear relaxation and contention resolution schemes". In: *SIAM Journal on Computing* 43.6, pp. 1831–1879.
- Das, A. and D. Kempe (2011). "Submodular meets spectral: greedy algorithms for subset selection, sparse approximation and dictionary selection". In: *Proceedings of the 28th International Conference on Machine Learning (ICML)*, pp. 1057–1064.
- Elenberg, E. R., R. Khanna, A. G. Dimakis, and S. Negahban (2018). "Restricted strong convexity implies weak submodularity". In: *Annals of Statistics* 46.6B, pp. 3539–3568.
- Lin, H. and J. Bilmes (2011). "A class of submodular functions for document summarization". In: *Proceedings of the Annual Conference of the North American Chapter of the Association for Computational Linguistics*, pp. 510–520.
- Mirzasoleiman, B., A. Badanidiyuru, A. Karbasi, J. Vondrak, and A. Krause (2015). "Lazier than lazy greedy". In: *Proceedings of AAAI Conference on Artificial Intelligence (AAAI)*.
- Nemhauser, G. L. and L. A. Wolsey (1978). "Best Algorithms for Approximating the Maximum of a Submodular Set Function". In: *Mathematics of Operations Research* 3.3, pp. 177–188.
- Nemhauser, G. L., L. A. Wolsey, and M. L. Fisher (1978). "An analysis of approximations for maximizing submodular set functions - II". In: *Mathematical Programming* 8, pp. 73–87.
- Ribeiro, M. T., S. Singh, and C. Guestrin (2016). "“Why should i trust you?” Explaining the predictions of any classifier". In: *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 1135–1144.

Sviridenko, M. (2004). "A note on maximizing a submodular set function subject to a knapsack constraint". In: *Operations Research Letters* 32.1, pp. 41–43.